Modellauswahl

Für das in der Belegarbeit geplante System, einen sprachbasierten Assistenzagenten, der komplette Machine-Learning-Pipelines allein über natürliche Sprache erstellt, konfiguriert und erklärt, ist das Large Language Model in erster Linie als „Orchestrator“ eines fest definierten Python-Backends konzipiert. Das Modell generiert keinen freien Code, sondern manipuliert eine strukturierte Pipeline-Spezifikation, über die deterministische Preprocessing-, Trainings- und Explainability-Funktionen angesteuert werden. Für diesen Anwendungsfall sind vor allem robuste Instruktionsbefolgung, zuverlässiges Tool-Calling, lange Kontextfenster und niedrige Latenz entscheidend, weniger komplexe Reasoning-Schritte.

GPT-4.1 mini adressiert genau dieses Profil. Laut offizieller Modelldokumentation ist GPT-4.1 mini eine kleinere, schnellere Variante von GPT-4.1, die speziell auf hohe Instruktions-Treue und Tool-Calling optimiert ist. Mit einem Kontextfenster von mehr als einer Million Tokens kann das Modell Systemprompt, laufende Konversation, die aktuelle Pipeline Spezifikation sowie zusammengefasste Ausführungsergebnisse und Log Informationen gleichzeitig verarbeiten.[1] Damit lassen sich auch längere Iterationszyklen konsistent in einem Durchlauf halten, ohne ständig Kontext wegwerfen zu müssen. Im offiziellen Modellvergleich wird GPT-4.1 als „smartest non-reasoning model“ geführt, während GPT-4.1 mini explizit als „smaller, faster version of GPT-4.1“ ausgewiesen ist, also die gleiche Modellfamilie, aber mit günstigerem Kosten-/Latenzprofil.[2]

Auch die verfügbaren Benchmarks zeigen, dass GPT 4.1 mini für unseren Orchestrator Einsatz mehr als ausreichend leistungsfähig ist. Auf der Wissensbenchmark MMLU erzielt das Modell 87,5 Prozent und weist damit eine hohe Abdeckung fachlicher Inhalte in vielen Domänen auf. In GPQA Diamond erreicht GPT 4.1 mini 65,0 Prozent und beweist, dass es auch bei sehr anspruchsvollen, forschungsnahen Fragen belastbar schlussfolgern kann. Für die Fähigkeit, Anweisungen präzise zu befolgen, sind mehrere Evaluierungen relevant. Ein internes Instruction Following Eval mit hohem Schwierigkeitsgrad berichtet 45,1 Prozent und misst, wie zuverlässig komplexe und verschachtelte Anweisungen umgesetzt werden. Der MultiChallenge Wert von 35,8 Prozent beschreibt, wie gut das Modell über längere Dialoge hinweg konsistent bleibt und mehrstufige Aufgaben korrekt weiterführt. IFEval konzentriert sich auf streng vorgegebene Ausgabeformate und liefert für GPT 4.1 mini einen Wert von 84,1 Prozent, was besonders wichtig für unsere strukturierte Pipeline Spezifikation ist. Zusätzlich zeigt das Modell im Benchmark ComplexFuncBench mit 49,3 Prozent, dass es Funktionsaufrufe und Tool Nutzung robust handhabt und passende Funktionen mit geeigneten Parametern auswählt, was direkt für die Orchestrierung unseres Backend Baukastens relevant ist.[3]

[1] Vgl. „GPT-4.1 Mini Model | OpenAI API“; „Introducing GPT-4.1 in the API“.
[2] Vgl. „Models | OpenAI API“.
[3] Vgl. „Introducing GPT-4.1 in the API“.

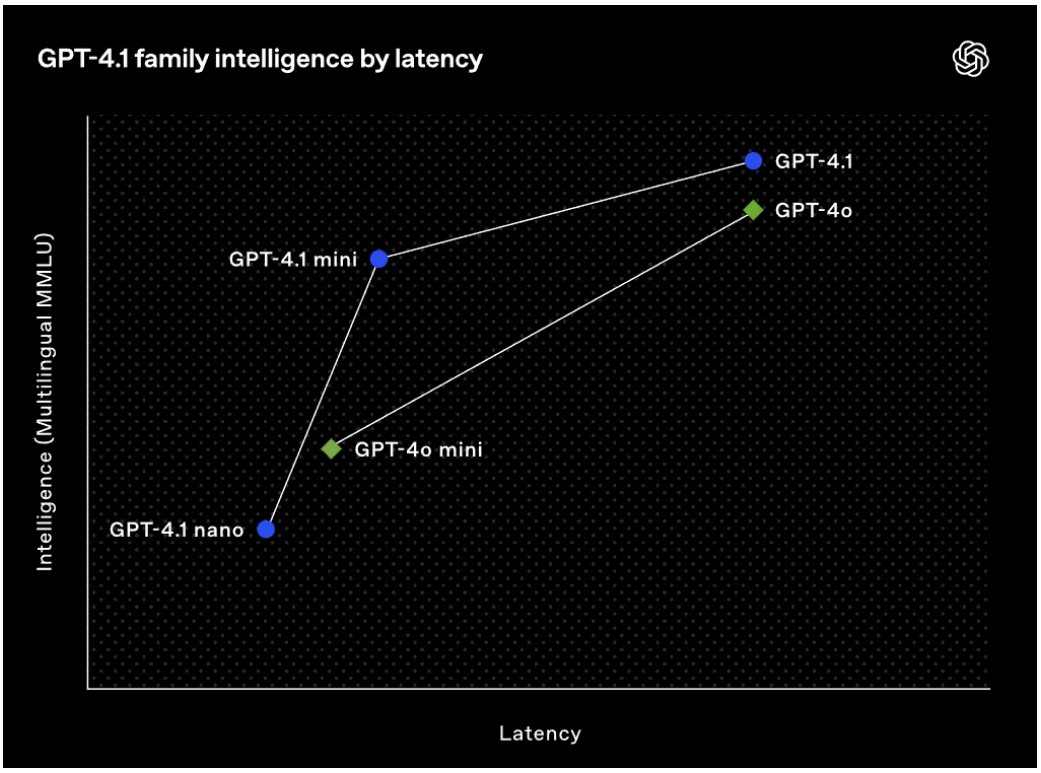


Abbildung 1: GPT-4.1 family intelligence by latency

Neben der Leistungsfähigkeit ist die Kostenseite entscheidend. GPT-4.1 mini wird in der OpenAI-Dokumentation mit 0,40 US-$ pro 1 Mio. Input-Tokens und 1,60 US-$ pro 1 Mio. Output-Tokens ausgewiesen, bei unverändertem 1-Mio.-Token-Kontextfenster.[4] Damit lassen sich selbst bei intensiver Nutzung, vielen Experimenten mit unterschiedlichen Pipelines und iterativen Dialogen, die Gesamtkosten im unteren zweistelligen Dollarbereich halten, ohne dass wir Abstriche bei Kontextlänge oder Modellqualität machen müssen. Gleichzeitig profitieren wir von der stabilen, voll gemanagten API-Infrastruktur, sodass wir uns in der Belegarbeit auf die Gestaltung der Pipeline-DSL, der Interaktionslogik und der Explainability-Workflows konzentrieren können, statt eigene Inferenzinfrastruktur zu betreiben.

Insgesamt bietet GPT-4.1 mini damit genau den Kompromiss, den unser Assistenzagent benötigt: ein hinreichend leistungsfähiges, instruktionsstabiles Modell mit sehr großem Kontextfenster und starker Tool-Unterstützung, das gleichzeitig kosteneffizient und operativ einfach über die OpenAI-API nutzbar ist. Vor diesem Hintergrund erscheint die Wahl von GPT-4.1 mini als Kernmodell für unseren Prototyp sowohl technisch als auch ökonomisch sinnvoll und gut begründbar.

[4] Vgl. „GPT-4.1 Mini Model | OpenAI API“.